

R Notebook

Code ▾

Hide

```
load("C:/Users/mabri/Downloads/dataS1.RData")
```

Hide

```
library(questionr)
```

Question 1

Oui, les fonctions var() et sd() sont adaptées à un usage en statistique inférentielle, car elles utilisent un estimateur non biaisé, ce qui est recommandé pour estimer les paramètres de la population à partir d'un échantillon.

Hide

```
echantillon <- data[1,]
```

$$\hat{m} = \bar{x} = \frac{1}{n} \sum_{i=1}^n X_i$$
$$\hat{\sigma} = s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

Hide

```
moy <- mean(echantillon)
moy
```

```
[1] 4.162802
```

Hide

```
ecart_type <- sd(echantillon)
ecart_type
```

```
[1] 4.295642
```

Hide

```
Ua <- qnorm(0.95)
IF <- c(moy-Ua*ecart_type,moy+Ua*ecart_type)
IF
```

```
[1] -2.9029 11.2285
```

Hide

```
cat("Intervalle de fluctuation de IF = [",IF[1],",",IF[2],"]")
```

```
Intervalle de fluctuation de IF = [ -2.9029 ; 11.2285 ]
```

Hide

```
N <- sum(echantillon >= IF[1] & echantillon <= IF[2])
N
```

```
[1] 931
```

Hide

```
som = c(50)
for (i in 1:50) {
  echantillon2 = data[i,]
  Ua <- qnorm(0.95)
  moy <- mean(echantillon2)
  ecart_type <- sd(echantillon2)
  IF2 <- c(moy-Ua*ecart_type,moy+Ua*ecart_type)
  t1 = sum(echantillon2 >= IF2[1] & echantillon2 <= IF2[2])
  som[i] = t1
}
min(som)
```

```
[1] 920
```

Hide

```
1-pbinom(919,1000,0.9)
```

```
[1] 0.01761157
```

Hide

```
load("C:/Users/mabri/Downloads/data.xlsx")
```

Warning: file 'data.xlsx' has magic number 'PK   '
Use of save versions prior to 2 is deprecated
Error in load("C:/Users/mabri/Downloads/data.xlsx") :
 bad restore file magic number (file may be corrupted) -- no data loaded

Hide

```
age_moyen <- mean(data$AGE)
age_moyen
```

```
[1] 41.20726
```

Hide

```
x <- data$AGE
```

Hide

```
echantillon <- sample(x,size = 100, replace = TRUE)
```

Hide

```
moy_echantillon <- mean(echantillon)
moy_echantillon
```

```
[1] 40.4
```

Hide

```
ecarttype <- sd(echantillon)
```

Hide

```
echantillon <- sample(x,size = 100, replace = TRUE)
moy_echantillon <- mean(echantillon)
ecarttype <- sd(echantillon)
IC <- c(moy_echantillon-(qnorm(0.975))*ecarttype/sqrt(100),moy_echantillon+(qnorm(0.975))*ecarttype/sqrt(100))
IC
```

```
[1] 36.99731 41.58269
```

Hide

```
n <- 50
som <- 0
for (i in 1:n) {
  echantillon <- sample(x,size = 100, replace = TRUE)
  moy_echantillon <- mean(echantillon)
  ecarttype <- sd(echantillon)
  IC <- c(moy_echantillon-(qnorm(0.975))*ecarttype/sqrt(100),moy_echantillon+(qnorm(0.975))*ecarttype/sqrt(100))
  t1 = (age_moyen >= IC[1] & age_moyen <= IC[2])
  som = som + t1
}
(som/n)*100
```

```
[1] 94
```

Hide

```
data$AGE_rec <- cut(data$AGE,
  include.lowest = TRUE,
  right = FALSE,
  dig.lab = 4,
  breaks = c(0, 30, 50, max(data$AGE)),
  labels = c("moins de 30 ans","entre 30 et 50 ans","plus de 50 ans")
)

t = table(data$AGE_rec)
prop.table(t)
```

moins de 30 ans	entre 30 et 50 ans	plus de 50 ans
0.1858974	0.5641026	0.2500000

Hide

```
y = sum(data$ACTIFS=="D") /936
y
```

```
[1] 0.4123932
```

Hide

```
x<- data$ACTIFS
echantillon <- sample(x,size = 50, replace = FALSE)
a = sum(echantillon=="D") /50
d <- (1.96*sqrt(a*(1-a)/50))
IC = c(a-d,a+d)
cat("Intervalle de condiance a 95% : [",IC[1],*"-",IC[2],"]")
```

```
Intervalle de condiance a 95% : [ 0.2642072 ~ 0.5357928 ]
```

Hide

```
n <- 50
som <- 0
for (i in 1:n) {
  echantillon <- sample(x,size = 50, replace = FALSE)
  a = sum(echantillon=="D") /50
  d <- (1.96*sqrt(a*(1-a)/50))
  IC = c(a-d,a+d)
  t1 = (y >= IC[1] & y <= IC[2])
  som = som + t1
}
som/n
```

```
[1] 0.92
```

Hide

```
library(readxl)
data_bretagne <- read_excel("C:/Users/mabri/Downloads/data_bretagne.xlsx")
```

Hide

```
som_population <- sum(data_bretagne$Pop)
echantillon <- sample(data_bretagne$Pop,100,replace = FALSE)
moy_echantillon <- mean(echantillon)
ecarttype <- sd(echantillon)
IC <- c(moy_echantillon-(qnorm(0.975))*ecarttype/sqrt(100),moy_echantillon+(qnorm(0.975))*ecarttype/sqrt(100))
IC
```

```
[1] 1513.548 2594.692
```

Hide

```
ICbretagne <- c((moy_echantillon-(qnorm(0.975))*ecarttype/sqrt(100))*1232,(moy_echantillon+(qnorm(0.975))*ecarttype/sqrt(100))*1232)
ICbretagne
```

```
[1] 1864691 3196661
```

Hide

```
n <- 50
som <- 0
y <- sum(data_bretagne$Pop)
for (i in 0:n) {
  echantillon <- sample(data_bretagne$Pop,100,replace = FALSE)
  moy_echantillon <- mean(echantillon)
  ecarttype <- sd(echantillon)
  ICbretagne <- c((moy_echantillon-(qnorm(0.975))*ecarttype/sqrt(100))*1232,(moy_echantillon+(qnorm(0.975))*ecarttype/sqrt(100))*1232)
  t1 = (y >= ICbretagne[1] & y <= ICbretagne[2])
  som = som + t1
}
som/50
```

```
[1] 0.78
```

Hide


Pas assez d'echantillon et trop petit

Hide

```
data_bretagne_ordre <- data_bretagne[order(-data_bretagne$Pop), ]

plot(data_bretagne$POP,
  names = data_bretagne_ordre$Nom,
  las = 1,
  col = "darkblue",
)
```

```
Warning in plot.window(...): "names" n'est pas un paramètre graphique
Warning in plot.xy(xy, type, ...):
  "names" n'est pas un paramètre graphique
Warning in axis(side = side, at = at, labels = labels, ...):
  "names" n'est pas un paramètre graphique
Warning in axis(side = side, at = at, labels = labels, ...):
  "names" n'est pas un paramètre graphique
Warning in box(...): "names" n'est pas un paramètre graphique
Warning in title(...): "names" n'est pas un paramètre graphique
```



Forte disparité entre les 6 premières villes

Si pas de grandes villes dans l'échantillon : -> m'a trop petit -> écart type trop petit les paramètres sont sous-estimés donc l'IC est d'amplitude trop faible

Hide

```
data_bretagne$POP_rec <- cut(data_bretagne$Pop,
  include.lowest = TRUE,
  right = FALSE,
  dig.lab = 4,
  breaks = c(0, 3000, 30000, max(data_bretagne$POP)),
  labels = c("moins de 3000","entre 3000 et 30000","plus de 30000 ")
)

t <- table(data_bretagne$POP_rec)
prop.table(t)*100
```

```
ech <- sample(data_bretagne, size = 100)
```

Hide

Error: object 'data_bretagne' not found

Q8 : tirer un échantillon stratifié : -> 79 petites communes -> 20 communes moyennes -> 1 grandes villes

Q9 : Tout les IC contiennent la vraie valeur m et sigma qui sont sur-estimés sigma trop élevé car on a forcé sur 1 grandes villes à être dans l'échantillon