Régression sur données réelles

CHAKRA Adam, ABRIC–SEGARRA Maxence

```
## Global options
knitr::opts_chunk$set(cache = TRUE)
```

1 Installation et importation des libraries utilisées

```
#Ajouter au fur et à mesure les librairies R que vous utilisez
library(skimr)
library(psych)
library(Hmisc)
library(GGally)
library(readxl)
library(corrplot)
```

```
Regressiondonneees_1 <- read_excel("Regressiondonneees 1.xlsx")
```

2 Séance 1

2.1 1. Définition de la problématique.

2.1.1 Population étudié

La population étudiée sont les départements de France Il y a 100 individus et chaque individus représente un département ### Liste des variables Nom_departement : Nom du département

Nombre _Habitants : Nombre habitants par département

Nombre_logements : Nombre de logements dans le département

Nombre_Logements_Sociaux : Nombres de logements sociaux parmi les logements

Nombre_logements_vacants : Nombres de logements vacants parmi les logements

Nombre_logements_individuels : Nombres de logements individuels parmi les logements ### Variable expliqué

Nombre_Logements_Sociaux : Nombres de logements sociaux parmi les logements

```
# Code utilisé pour illustrer la réponse
dim(x = Regressiondonneees_1) # donne le nombre de lignes et colonnes
```

```
## [1] 100   6
```

```
names(x = Regressiondonneees_1) # donne les noms des variables
```

```
## [1] "nom_departement"              "Nombre _habitants"
## [3] "Nombre_de_logements"          "Nombre_Logements_Sociaux"
## [5] "Nombre_logements_vacants"     "Nombre_logements_individuels"
```

2.1.2 2. Analyses descriptives univariées

```
# Code pour réaliser l'analyse univariées
summary(Regressiondonneees_1)
```

```
##  nom_departement    Nombre _habitants Nombre_de_logements
##  Length:100         Min.   :  76593   Min.   :  61734
##  Class :character   1st Qu.: 297338   1st Qu.: 166443
##  Mode  :character   Median : 531129   Median : 297099
##                     Mean   : 673464   Mean   : 367267
##                     3rd Qu.: 849424   3rd Qu.: 478916
##                     Max.   :2607335   Max.   :1393800
##  Nombre_Logements_Sociaux Nombre_logements_vacants Nombre_logements_individuels
##  Min.   :  4939           Min.   :  3710           Min.   : 13938
##  1st Qu.: 19090           1st Qu.: 18128           1st Qu.:119845
##  Median : 44387           Median : 26381           Median :179797
##  Mean   : 62877           Mean   : 30051           Mean   :202946
##  3rd Qu.: 80603           3rd Qu.: 38053           3rd Qu.:254862
##  Max.   :310310           Max.   :125442           Max.   :806807
```

```
psych::describe(Regressiondonneees_1)
```

```
##                              vars   n      mean        sd    median   trimmed
## nom_departement*                1 100     50.50     29.01     50.50     50.50
## Nombre _habitants               2 100 673463.99 517327.14 531129.00 598617.52
## Nombre_de_logements             3 100 367267.37 262794.01 297098.50 329351.48
## Nombre_Logements_Sociaux        4 100  62876.57  62981.79  44387.10  50270.50
## Nombre_logements_vacants        5 100  30051.00  18840.48  26380.97  27678.46
## Nombre_logements_individuels    6 100 202946.39 122630.18 179797.13 188619.70
##                                    mad      min       max     range skew
## nom_departement*                 37.06     1.00     100.0      99.0 0.00
## Nombre _habitants            383579.75 76593.00 2607335.0 2530742.0 1.32
## Nombre_de_logements          205741.14 61734.00 1393800.0 1332066.0 1.43
## Nombre_Logements_Sociaux      38766.02  4938.72  310310.2  305371.5 1.91
## Nombre_logements_vacants      13158.82  3709.50  125442.0  121732.5 2.07
## Nombre_logements_individuels 101912.78 13938.00  806806.7  792868.7 1.74
##                              kurtosis       se
## nom_departement*                -1.24     2.90
## Nombre _habitants                1.41 51732.71
## Nombre_de_logements              2.14 26279.40
## Nombre_Logements_Sociaux         3.61  6298.18
## Nombre_logements_vacants         6.79  1884.05
## Nombre_logements_individuels     5.12 12263.02
```

```
Hmisc::describe(Regressiondonneees_1)
```

```
## Regressiondonneees_1
##
##  6  Variables      100  Observations
## --------------------------------------------------------------------------------
## nom_departement
##        n  missing distinct
##      100        0      100
##
## lowest : Ain                     Aisne                   Allier                  Alpes
-de-Haute-Provence Alpes-Maritimes
## highest: Vendée                  Vienne                  Vosges                  Yonne
Yvelines
## --------------------------------------------------------------------------------
## Nombre _habitants
##        n  missing distinct     Info     Mean  pMedian      Gmd      .05
##      100        0      100        1   673464   590813   545963   153717
##      .10      .25      .50      .75      .90      .95
##   180539   297338   531129   849424  1437756  1655802
##
## lowest :   76593  115050  138976  140230  144123
## highest: 1664856 1895426 2055002 2131104 2607335
## --------------------------------------------------------------------------------
## Nombre_de_logements
##        n  missing distinct     Info     Mean  pMedian      Gmd      .05
##      100        0      100        1   367267   330466   275910   100494
##      .10      .25      .50      .75      .90      .95
##   123297   166443   297099   478916   736993   819987
##
## lowest :   61734   73384   88769   88986  100007
## highest:  900198  949531 1055315 1241241 1393800
## --------------------------------------------------------------------------------
## Nombre_Logements_Sociaux
##        n  missing distinct     Info     Mean  pMedian      Gmd      .05
##      100        0      100        1    62877    49613    61439     9185
##      .10      .25      .50      .75      .90      .95
##    12773    19090    44387    80603   141519   196457
##
## lowest : 4938.72 5543.75 7207.38 7849.38 8876.9
## highest: 199402  228414  257576  292698  310310
## --------------------------------------------------------------------------------
## Nombre_logements_vacants
##        n  missing distinct     Info     Mean  pMedian      Gmd      .05
##      100        0      100        1    30051    27676    18855     8870
##      .10      .25      .50      .75      .90      .95
##    12056    18128    26381    38053    52315    57382
##
## lowest : 3709.5  4053.75 6173.4  8072.24 8325.06
## highest: 62671.8 66467.2 84425.2 99299.3 125442
## --------------------------------------------------------------------------------
## Nombre_logements_individuels
##        n  missing distinct     Info     Mean  pMedian      Gmd      .05
##      100        0      100        1   202946   188261   126768    64136
##      .10      .25      .50      .75      .90      .95
##    77562   119845   179797   254862   360148   390751
##
## lowest : 13938   34490.5 48152.5 55171.3 61050.4
## highest: 396154  473486  549121  557600  806807
## --------------------------------------------------------------------------------
```

2.1.3 Moyennes des Variables

```
moy_habitant <- mean(Regressiondonneees_1$`Nombre _habitants`)
moy_logement <- mean(Regressiondonneees_1$Nombre_de_logements)
moy_sociaux <- mean(Regressiondonneees_1$Nombre_Logements_Sociaux)
moy_vacants <- mean(Regressiondonneees_1$Nombre_logements_vacants)
moy_individuels <- mean(Regressiondonneees_1$Nombre_logements_individuels)
```

```
hist(Regressiondonneees_1$Nombre_Logements_Sociaux, main="Histogramme de nombre de logeme
nt sociaux", xlab="Nombre de logement sociaux",ylab = "nombre de département" ,ylim = c
(0,60),col="blue", border="black")
```

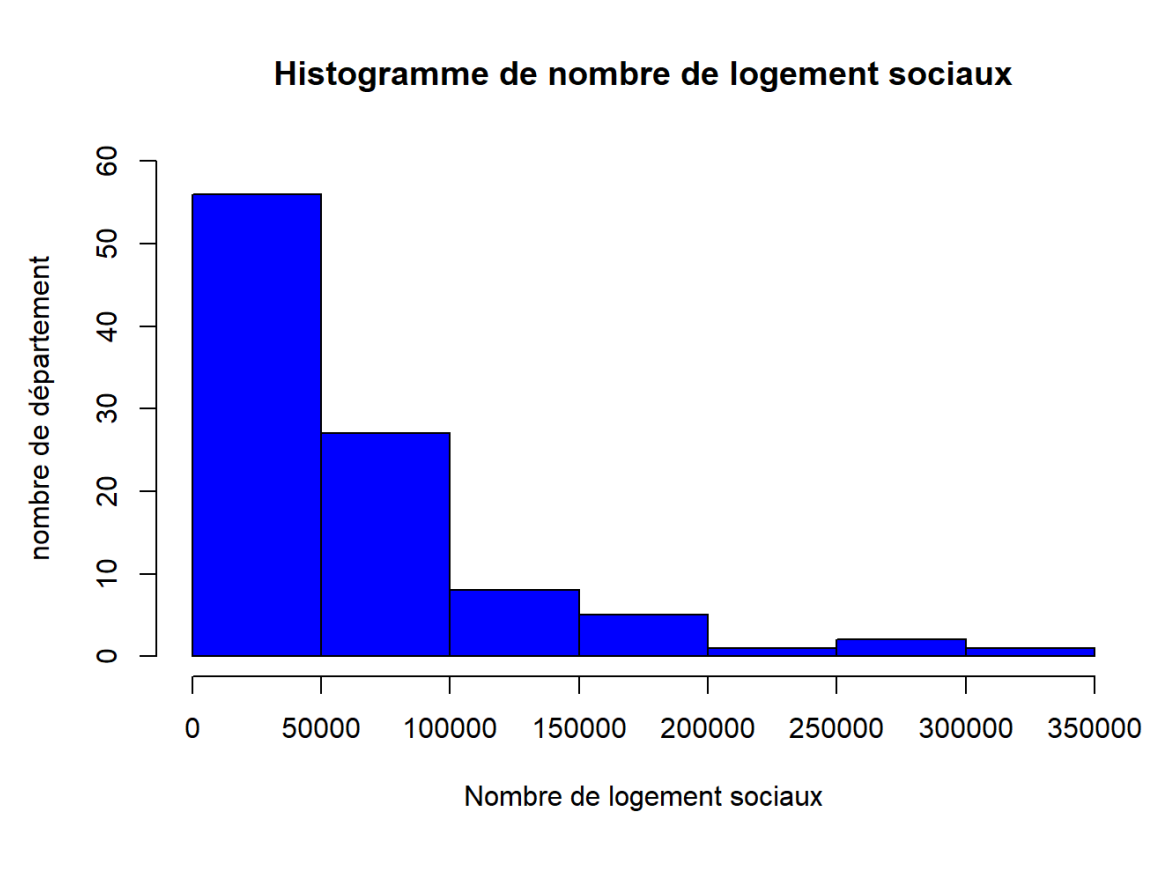

2.1.4 Variance

```
var_sociaux<- mean(Regressiondonneees_1$Nombre_Logements_Sociaux*Regressiondonneees_1$Nom
bre_Logements_Sociaux) - mean(Regressiondonneees_1$Nombre_Logements_Sociaux)*mean(Regress
iondonneees_1$Nombre_Logements_Sociaux)
var_sociaux
```

```
## [1] 3927038881
```

```
var_logement <- mean(Regressiondonneees_1$Nombre_de_logements * Regressiondonneees_1$Nomb
re_de_logements) - mean(Regressiondonneees_1$Nombre_de_logements) * mean(Regressiondonnee
es_1$Nombre_de_logements)
var_logement
```

```
## [1] 68370086524
```

2.1.5 2. Analyses descriptives bivarié

```
ggpairs(Regressiondonneees_1[,c("Nombre _habitants","Nombre_de_logements","Nombre_Logemen
ts_Sociaux","Nombre_logements_vacants","Nombre_logements_individuels")],progress=FALSE)
```

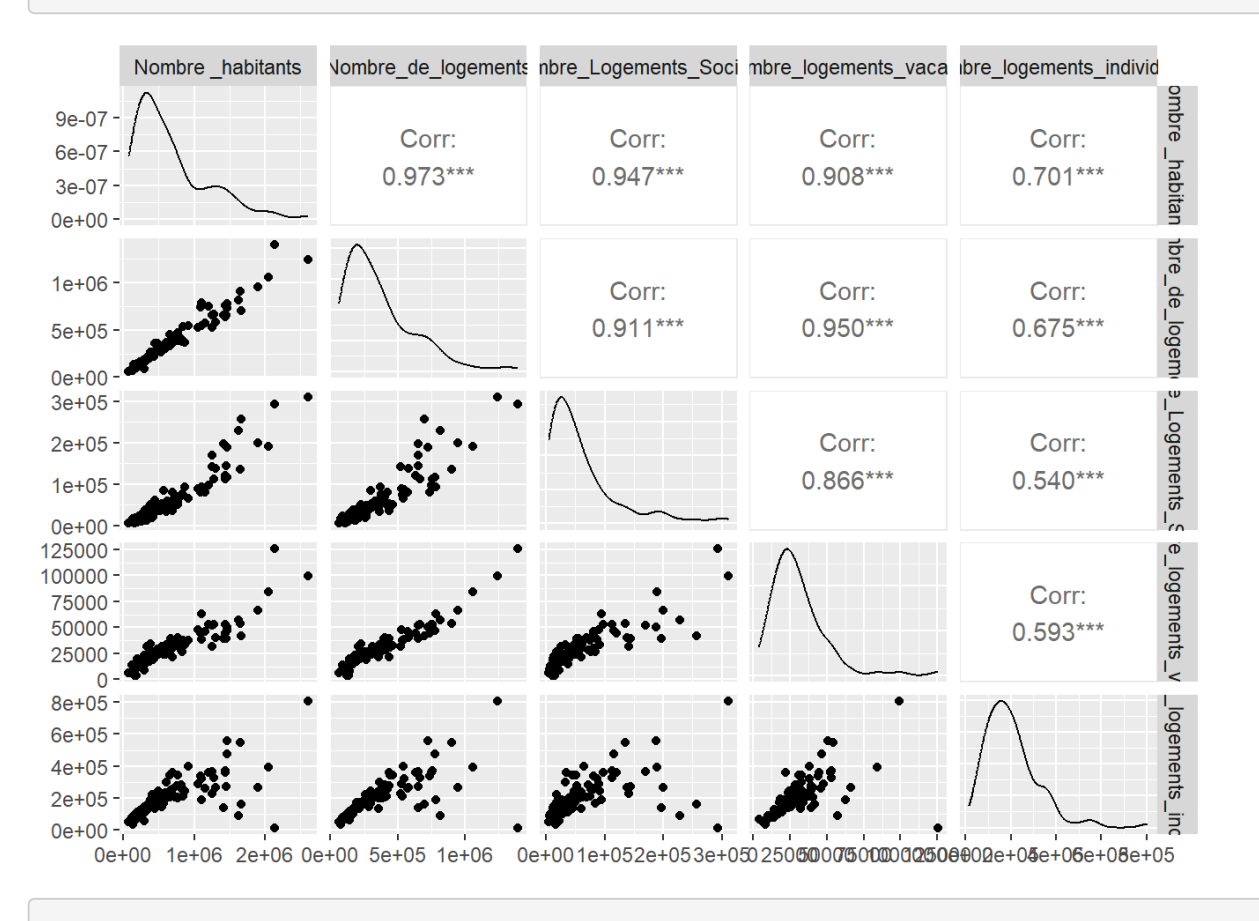

```
corr_matrix <- cor(Regressiondonneees_1[, c("Nombre _habitants","Nombre_de_logements","No
mbre_Logements_Sociaux","Nombre_logements_vacants","Nombre_logements_individuels")], meth
od = "pearson")
corr_matrix
```

```
##                              Nombre _habitants Nombre_de_logements
## Nombre _habitants                    1.0000000           0.9732735
## Nombre_de_logements                  0.9732735           1.0000000
## Nombre_Logements_Sociaux             0.9469860           0.9105020
## Nombre_logements_vacants             0.9079884           0.9499858
## Nombre_logements_individuels         0.7011271           0.6754122
##                              Nombre_Logements_Sociaux Nombre_logements_vacants
## Nombre _habitants                           0.9469860                0.9079884
## Nombre_de_logements                         0.9105020                0.9499858
## Nombre_Logements_Sociaux                    1.0000000                0.8660336
## Nombre_logements_vacants                    0.8660336                1.0000000
## Nombre_logements_individuels                0.5404343                0.5925038
##                              Nombre_logements_individuels
## Nombre _habitants                               0.7011271
## Nombre_de_logements                             0.6754122
## Nombre_Logements_Sociaux                        0.5404343
## Nombre_logements_vacants                        0.5925038
## Nombre_logements_individuels                    1.0000000
```

```
corrplot(corr_matrix,
         method = "color",
         col = colorRampPalette(c("blue", "white", "red"))(200),
         addCoef.col = "black",
         tl.col = "black",
         tl.srt = 45)
```

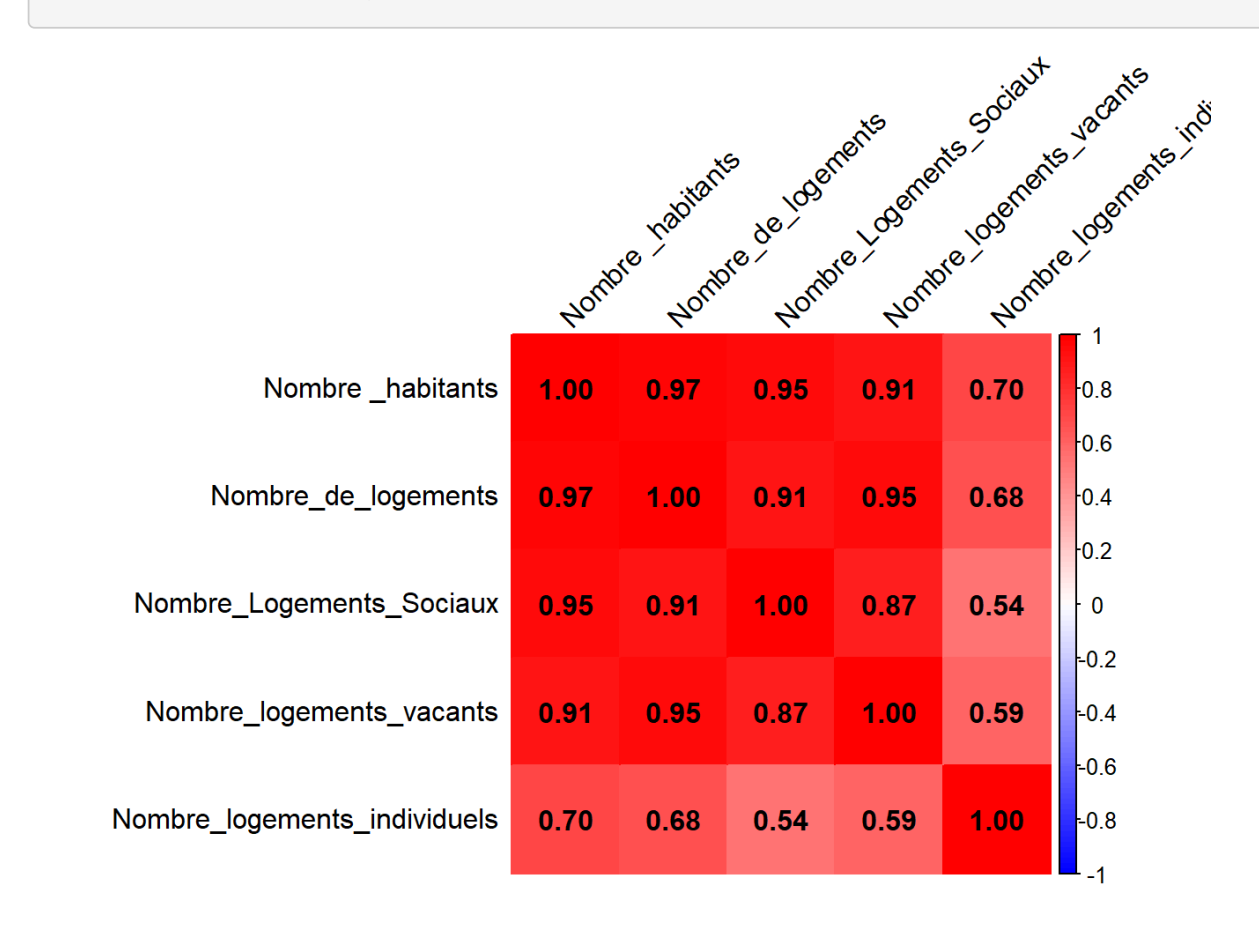

2.1.6 Analyse fonction pairs x corrplot

Les variables Nombre _habitants et Nombre_de_logements sont fortement corrélées, tandis que les relations entre Nombre_logements_vacants et Nombre_logements_individuels sont faibles. Le ggpairs offre une visualisation détaillée des relations, et corrplot résume ces relations avec une représentation visuelle claire.

2.1.7 interpretation

On a choisi le Nombre_Logements_Sociaux comme variable explicative, car il présente une corrélation de 0.91 avec Nombre_de_logements.

3 Séance 2

3.1 Equation du modèle :

$$totlogsoc_i = a \times totlog_i + b + e_i$$

avec :

- $totlog_i$ = L'observation du nombre de logement
- $totlogsoc_i$ = L'observation du nombre de logements sociaux b = l'ordonnée à l'origine a = La pente e_i = Les erreurs inconnues

â = \frac{\text{cov}(totlog, totlogsoc)}{\text{var}(totlog)} # formule des MCO â égale à la covaiance de X et Y divisé par la variance de X

\hat{b} = \bar{totlogsoc} - â \times \bar{totlog} # b chapeau égale à la moyenne des logements sociaux - le â multiplié par la moyenne des logements totales

$$\widehat{totlogsoc} = a \times totlog + b$$

b = la moyenne(totlog) - â * moyenne(totlogsoc)

$$P(a,b) = \sum_{i=1}^{n}(y_i - ax_i - b)^2$$

```
model <- lm(Nombre_Logements_Sociaux ~ Nombre_de_logements, data = Regressiondonneees_1)
plot(Regressiondonneees_1$Nombre_de_logements, Regressiondonneees_1$Nombre_Logements_Soci
aux,ylab ="nombre de logement sociaux",xlab= "nombre de logements")
```

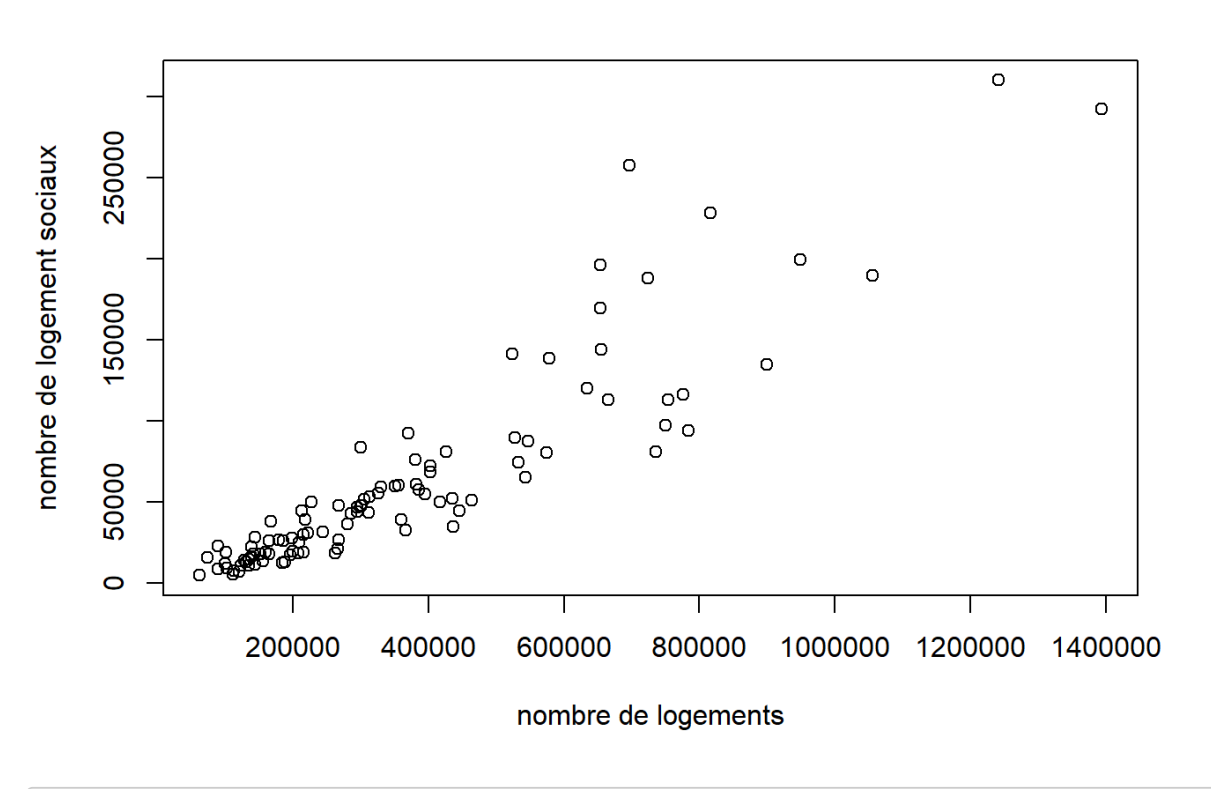

```
summary(model)
```

```
##
## Call:
## lm(formula = Nombre_Logements_Sociaux ~ Nombre_de_logements,
##     data = Regressiondonneees_1)
##
## Residuals:
##    Min     1Q Median     3Q    Max
## -62330 -10077    114   7142 122933
##
## Coefficients:
##                       Estimate Std. Error t value Pr(>|t|)
## (Intercept)         -1.727e+04  4.513e+03  -3.826  0.00023 ***
## Nombre_de_logements  2.182e-01  1.001e-02  21.798  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 26180 on 98 degrees of freedom
## Multiple R-squared:  0.829,  Adjusted R-squared:  0.8273
## F-statistic: 475.1 on 1 and 98 DF,  p-value: < 2.2e-16
```

```
produit <- Regressiondonneees_1$Nombre_de_logements * Regressiondonneees_1$Nombre_Logemen
ts_Sociaux
covariance<-mean(produit) - moy_sociaux * moy_logement
covariance
```

```
## [1] 14919235183
```

```
â <- covariance / var_logement
â
```

```
## [1] 0.2182129
```

```
b_chapeau <- moy_sociaux - â * moy_logement
b_chapeau
```

```
## [1] -17265.91
```

3.2 Equation de la droite ajustée :

$$\widehat{totlogsoc_i} = \hat{a}(totlog) + \hat{b}$$

$$\widehat{totlogsoc_i} = 0.2182129(totlogsoc)_i - 17\,265.91$$

```
plot(Regressiondonneees_1$Nombre_de_logements,
Regressiondonneees_1$Nombre_Logements_Sociaux,
col="orange",pch=20,
xlab="nombre de logement sociaux",
ylab="nombre de logement totale",
main="")
abline(model,col="red")
```

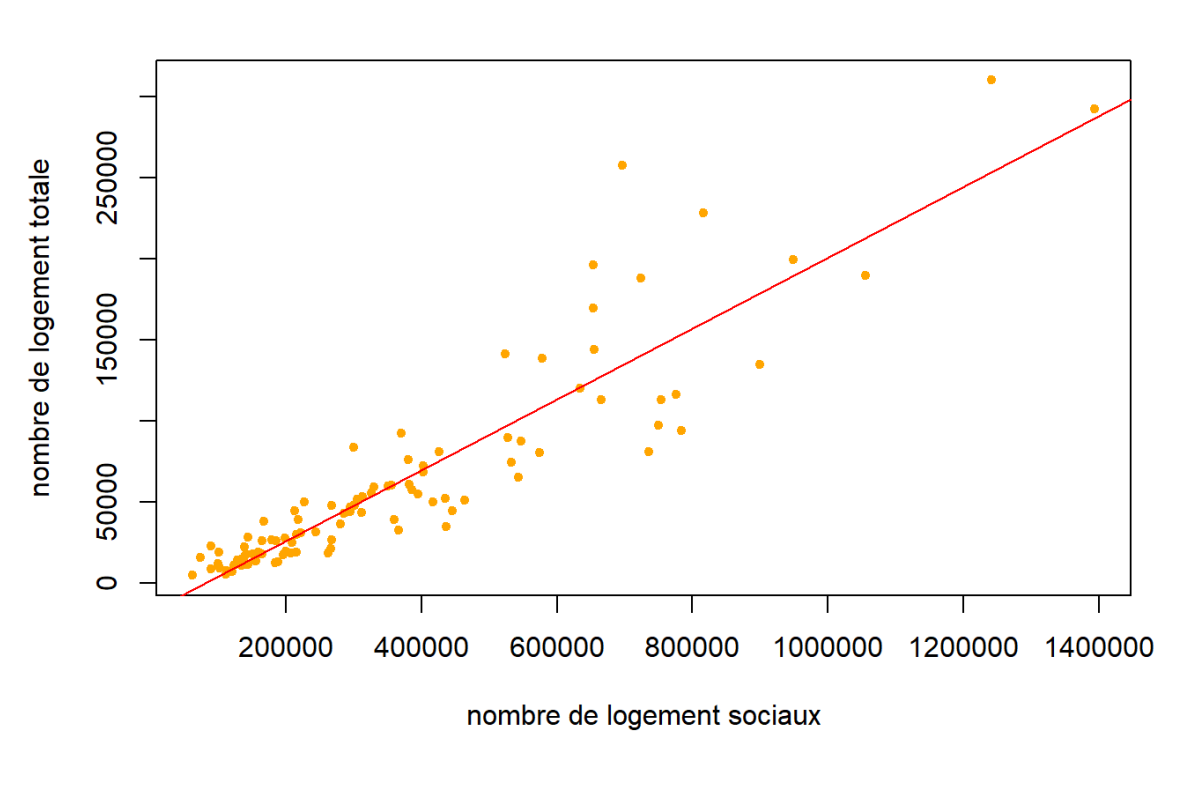

3.2.1 Coefficient de détermination R²

$$R^2 = 0.829$$

$$R^2 ajustée = 0.8273$$

```
Regressiondonneees_1$Nombre_de_logements2 <- (Regressiondonneees_1$ Nombre_de_logements)^
2 # Création d'une nouvelle variable 'Nombre_de_logements2' qui est le carré de 'Nombre_d
e_logements'
mod2 <- lm(formula =Nombre_Logements_Sociaux~Nombre_de_logements + Nombre_de_logements2,
data = Regressiondonneees_1) # Création du modèle de régression linéaire mod2 avec 'Nombr
e_de_logements' et 'Nombre_de_logements2' comme variables explicatives
summary(mod2)
```

```
##
## Call:
## lm(formula = Nombre_Logements_Sociaux ~ Nombre_de_logements +
##     Nombre_de_logements2, data = Regressiondonneees_1)
##
## Residuals:
##    Min     1Q Median     3Q    Max
## -59313 -10519   -415   5773 126465
##
## Coefficients:
##                        Estimate Std. Error t value Pr(>|t|)
## (Intercept)          -8.737e+03  7.003e+03  -1.248    0.215
## Nombre_de_logements   1.721e-01  3.074e-02   5.598 2.01e-07 ***
## Nombre_de_logements2  4.132e-08  2.608e-08   1.584    0.116
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 25980 on 97 degrees of freedom
## Multiple R-squared:  0.8333, Adjusted R-squared:  0.8299
## F-statistic: 242.5 on 2 and 97 DF,  p-value: < 2.2e-16
```

```
plot(Regressiondonneees_1$Nombre_de_logements,
Regressiondonneees_1$Nombre_Logements_Sociaux,
col="orange",pch=20,
xlab="nombre de logement sociaux",
ylab="nombre de logement totale",
main="")
abline(model,col="red")
curve(mod2$coef[1]+mod2$coef[2]*x+mod2$coef[3]*x^2,0,1400000,add=T,col="blue")
```

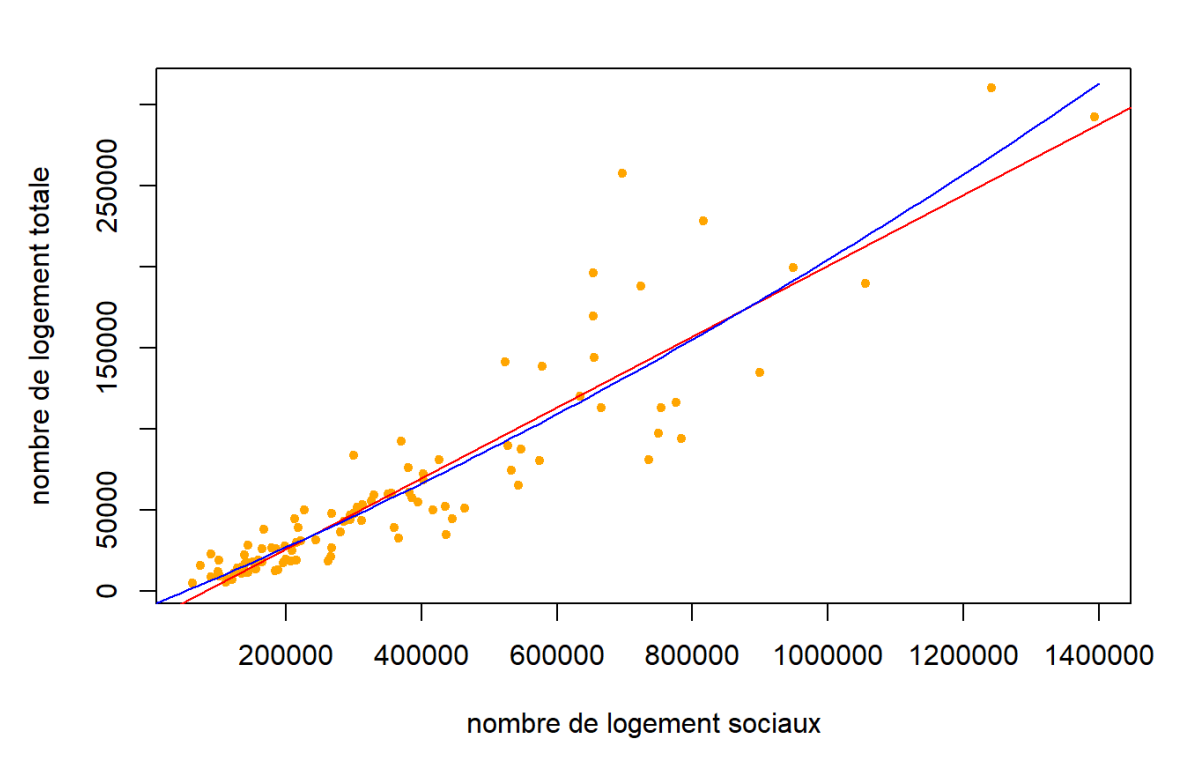

la pente positive de la ligne de regression montre une relation positive entre le nombre de logements sociaux et le nombre de logements. Cela signifie que une augmentation du nombre de logements sociaux est associé a une augmentation du nombre de logements

3.2.2 Equation du modèle

$$totlogsoc_i = a \times \sqrt{totlog} + b$$

3.2.3 Equation du modèle ajustée

$$totlogsoc_i = a \times totlog^2 + a \times totlog + b$$

3.2.4 Coefficient de détermination R²

$$R^2 = 0.9005$$

3.2.5 Coefficient de détermination R² ajustée

$$R^2 ajustée = 0.8985$$

4 Séance 3

Pour comparer les ajustements nous pouvons comparer le R² du modèle 1 par rapport au R² du modèle 2

-$Les\ deux\ Critères$: on peut utiliser R² ou la variance de chacun des modèles

mod1, R² = 0.829 : Cela signifie que 82.9% de la variance de la variable dépendante est expliquée par le modèle 1. mod2, R² = 0.900 : Cela signifie que 90% de la variance de la variable dépendante est expliquée par le modèle 2.

4.1 Définition du résidus

$$e_i = y_i - \bar{y}$$

## Valeur des résidus pour chaque modèle

```
residus <- residuals(model) # utilisation de la fonction residuals
residus
```

```
##            1            2            3            4            5            6
##   1575.93993   7041.86000  -3285.23479   1839.12968 -59673.87946  -9392.36984
##            7            8            9           10           11           12
##  14654.14678  -1384.69207  19233.50998 -14282.39165  -9961.09329 -27706.58473
##           13           14           15           16           17           18
## -23060.73790   5245.26961   4158.19564  -6346.64113 -35407.15595   5029.26897
##           19           20           21           22           23           24
##  -2680.80891   1412.38807  -2841.61348 -29747.57882   6772.27241  -7917.79322
##           25           26           27           28           29           30
## -21613.44365  -2227.28806  -7429.11252  29852.58008   -164.13599   8918.95432
##           31           32           33           34           35           36
## -36031.97080 -25533.79697    646.20789 -44139.20674  17672.52258  20984.38021
##           37           38           39           40           41           42
##   2643.64499 -34193.62879  -2697.83464  14429.95256   3638.77500   3322.13990
##           43           44           45           46           47           48
## -24447.92227   -539.97867    -80.06606  -9069.86097  67669.66345 -48893.94129
##           49           50           51           52           53           54
## -14543.94596   9176.70671   4638.30650 -14813.12102   2434.88121  29023.80132
##           55           56           57           58           59           60
## -19489.04403  -2176.13297 -35681.42046    341.83420   2750.30254  -1739.09501
##           61           62           63           64           65           66
## -10615.89790   8733.47829   1860.11368   -260.30371  35766.26758  15520.03909
##           67           68           69           70           71           72
##   1662.43671  -4962.62574   7443.93578 -32965.00168  -8182.40022   4808.57555
##           73           74           75           76           77           78
##  56721.35956  10344.95528   7661.48301   5818.76701  47526.28945 -13609.41255
##           79           80           81           82           83           84
## -23717.64394 -21598.85923   9467.50602   2181.06009    106.03010    122.61012
##           85           86           87           88           89           90
##   -625.66661  44581.30213 122932.80364   2542.65688 -10426.40692  -1350.53525
##           91           92           93           94           95           96
##  17397.05795  70782.48161  44356.05396 -62329.76375  -7065.96451 -42988.41674
##           97           98           99          100
##  -4242.24491    464.84324   1789.92628  18435.99824
```

```
residus2 <- residuals(mod2)
residus2
```

```
##            1            2            3            4            5            6
##   3670.27030   7886.79831  -3978.82397  -1378.52558 -57454.78273 -10124.30346
##            7            8            9           10           11           12
##  11885.12177  -5311.12745  17247.12254 -13453.73001 -11417.39384 -23395.19142
##           13           14           15           16           17           18
## -28968.37950   8852.94351    -90.41211  -7317.68067 -31602.96895   3438.89104
##           19           20           21           22           23           24
##  -5039.16518  -2049.04713  -1374.56429 -26931.69473   2009.33414  -8987.65203
##           25           26           27           28           29           30
## -20895.14271   -959.28429  -6293.35040  34159.79607   1402.91152   8486.29718
##           31           32           33           34           35           36
## -31717.56453 -21824.32272  -3233.80177 -44662.25883  17491.37458  16229.84961
##           37           38           39           40           41           42
##   -411.60728 -31468.36971  -5431.29575  10116.70640    709.61043     46.29567
##           43           44           45           46           47           48
## -20148.72500  -2603.55929   -419.36942  -5963.27849  69241.79316 -46098.05865
##           49           50           51           52           53           54
## -10225.44951   6254.74202   6828.01546 -10968.22840    -76.07858  31889.96633
##           55           56           57           58           59           60
## -18683.18050   1161.82656 -33330.34073   2900.44905   1352.24086  -5327.56252
##           61           62           63           64           65           66
## -11936.45084   2892.62556   5196.83467   1341.89394  37333.35779  14921.77224
##           67           68           69           70           71           72
##   -586.73348  -1916.82303   3111.29614 -29002.68525  -3895.54394   1964.60983
##           73           74           75           76           77           78
##  41739.56285  13363.78840   5612.28813 -18742.45525  50705.29228 -10382.85615
##           79           80           81           82           83           84
## -20208.62719 -18904.22551   7447.59094   4027.95331   1573.12274   2758.03593
##           85           86           87           88           89           90
##   3456.56444  48524.48359 126464.60294   4235.47717 -10927.89314  -4420.84703
##           91           92           93           94           95           96
##  12028.10934  74720.41062  48630.31769 -59312.80816  -5255.25798 -39277.25086
##           97           98           99          100
##  -3989.69709    -69.88262    763.24420  22370.71840
```

4.2 Analyse de la qualité d'ajustement pour chaque modèle

```
plot(residus)
```

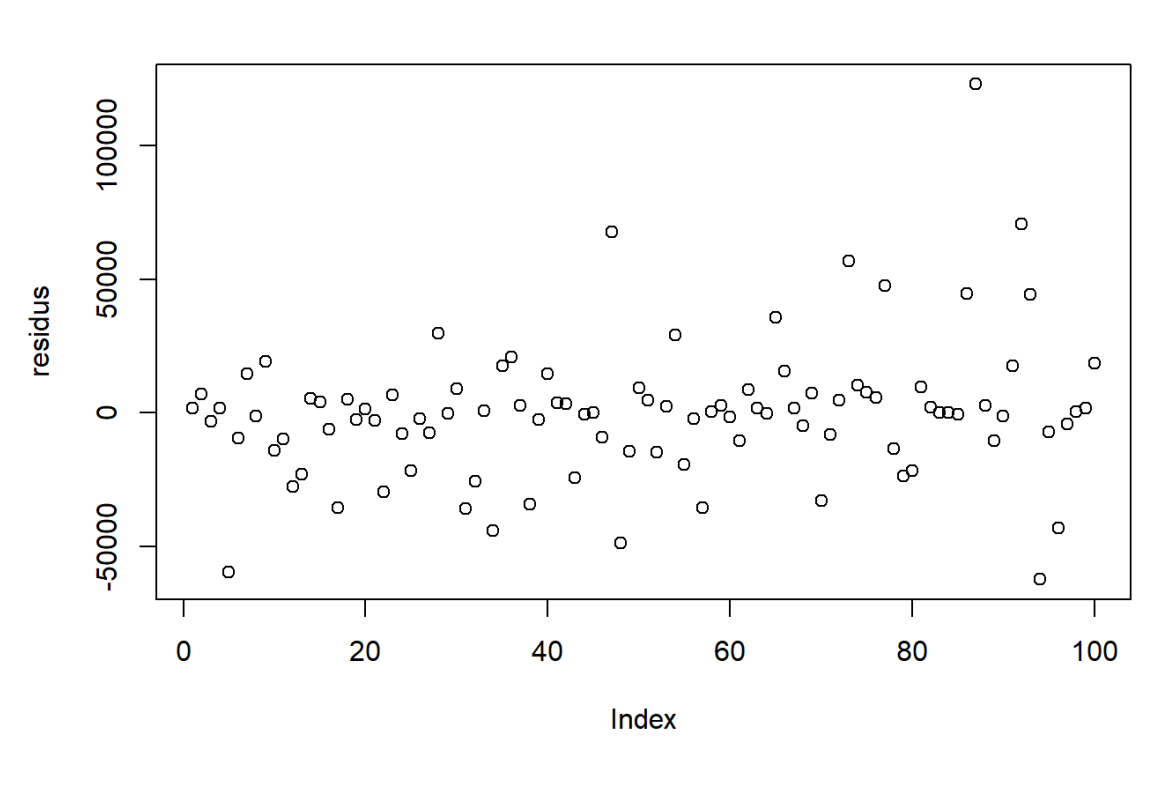

```
hist(residus, main = "Distribution des résidus du modèle 1   ")
```

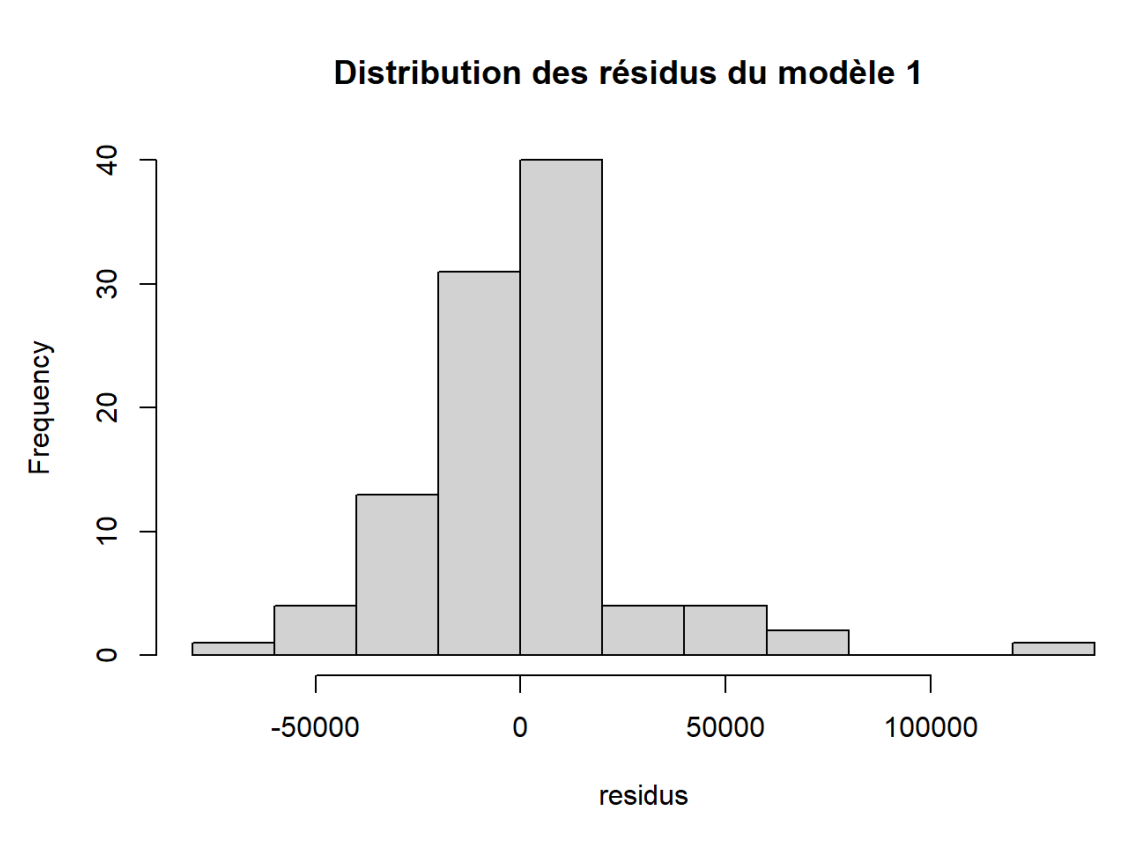

```
sigma_res<-summary(model)$sigma # Récupération de l'écart-type des résidus du modèle
plot(1:nrow(Regressiondonneees_1),residus,pch=20,xlab="",
           ylab="Résidus")# Traçage du graphique des résidus
abline(h=2*sigma_res,col="orange",lwd=2) # Tracé des lignes horizontales à ± 2 écarts-typ
es des résidus
abline(h=-2*sigma_res,col="orange",lwd=2)
```

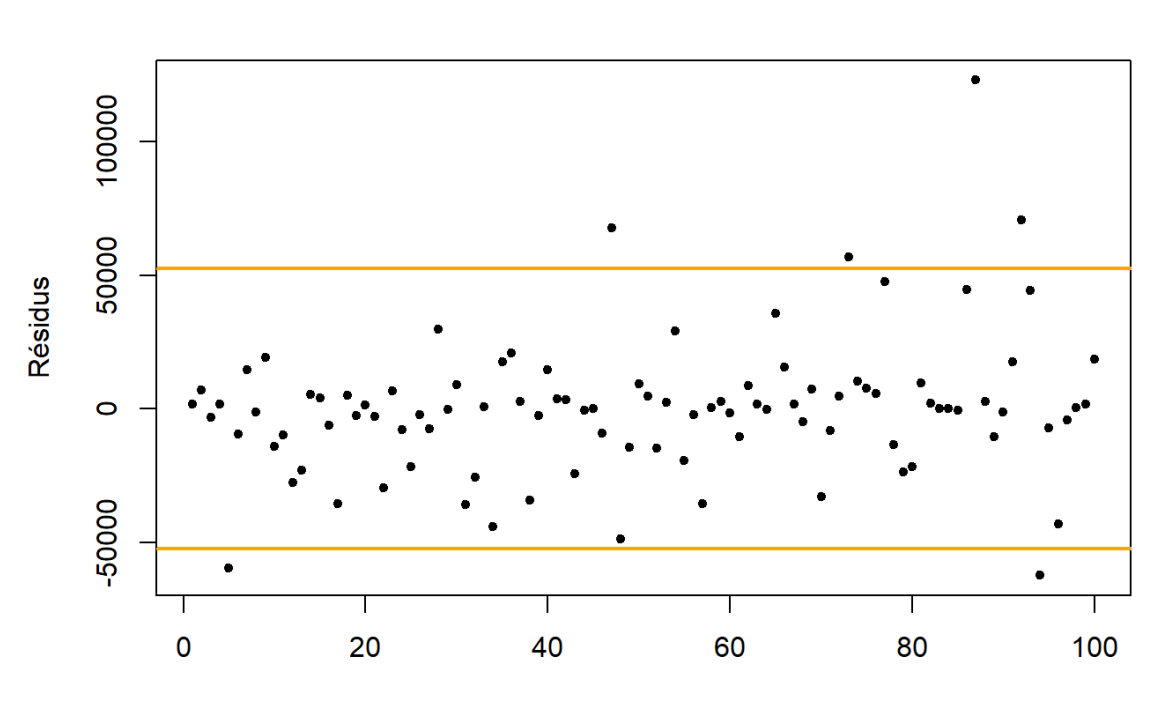

```
hist(residus2, main = "Distribution des résidus du modèle 2   ") # traçage d'un hidtogram
me
```

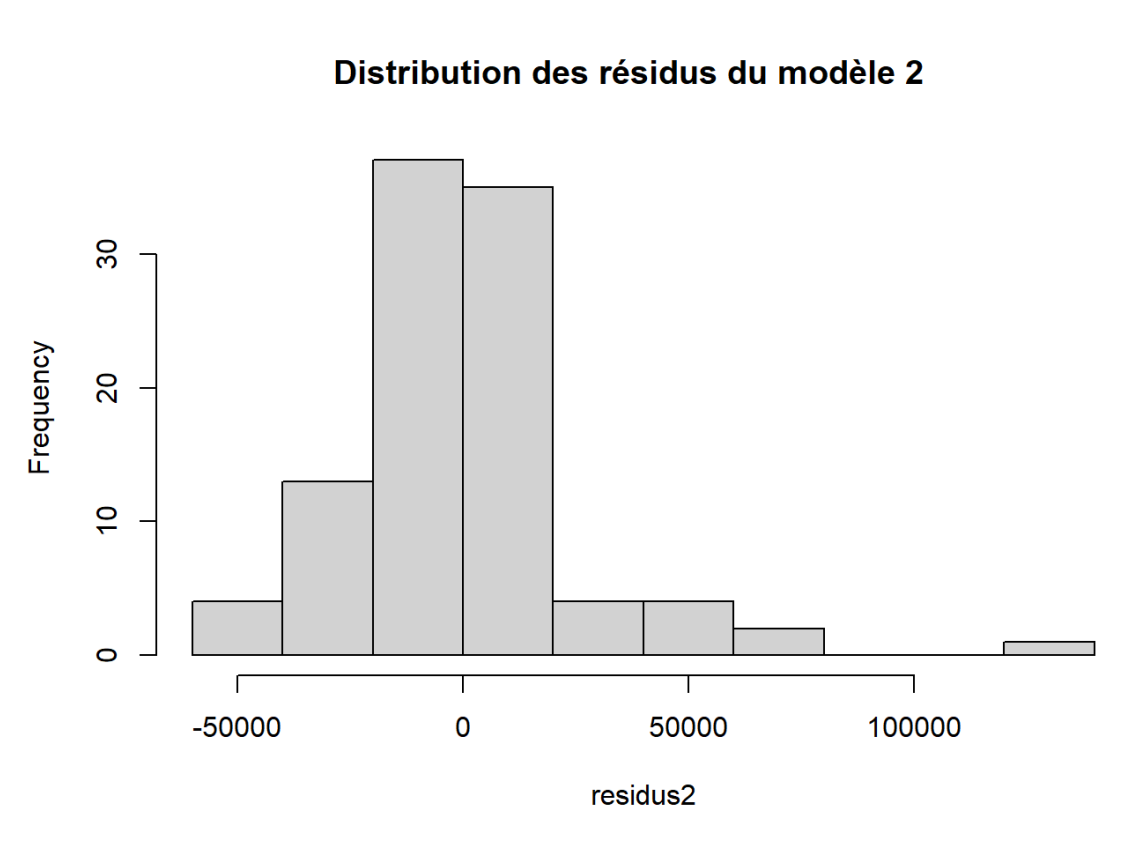

```
sigma_res2<-summary(mod2)$sigma
plot(1:nrow(Regressiondonneees_1),residus2,pch=20,xlab="",
           ylab="Résidus")
abline(h=2*sigma_res2,col="orange",lwd=2)
abline(h=-2*sigma_res2,col="orange",lwd=2)
```

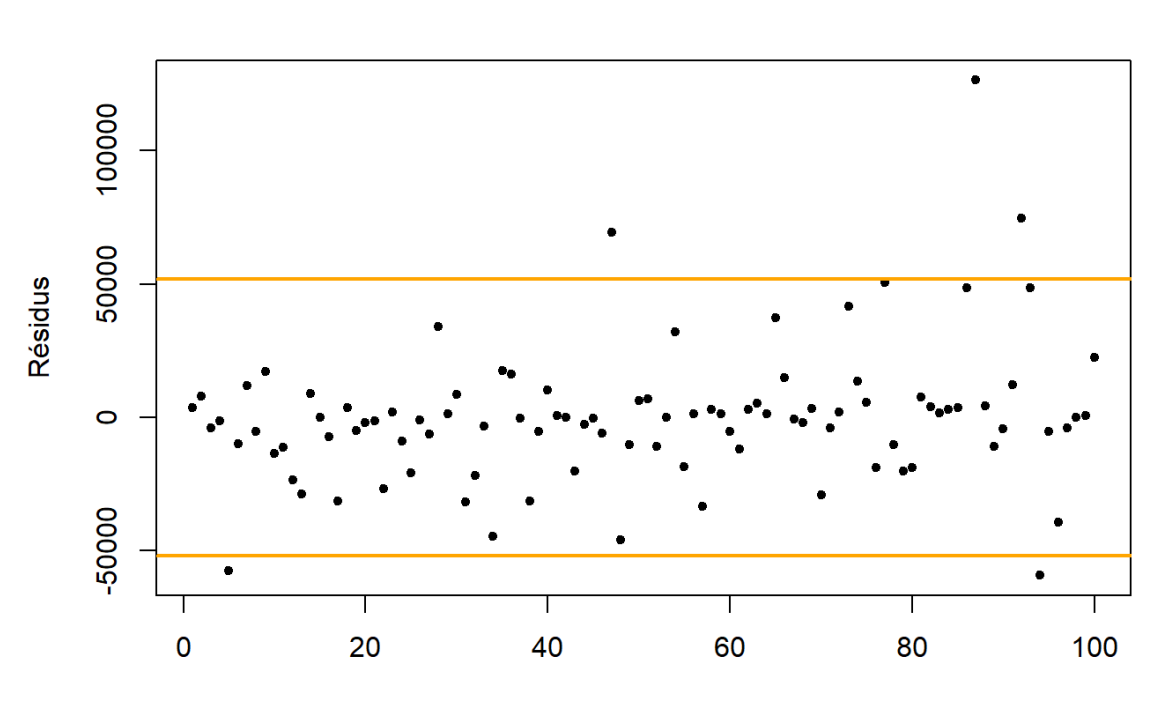

Les résidus supérieurs et inférieurs à 50 000 indiquent que, pour certains quartiers, l'écart entre les valeurs observées et celles prédites par le modèle est très important.

sur notre modèle 1 on en observe 6 et sur notre modele 2 on en observe seulement 5

Le modèle 2 (avec R² = 0.900) semble mieux ajuster les données que le modèle 1 (R² = 0.829), ce qui suggère que mod2 pourrait être un modèle plus performant.